


图7 PPO 训练循环:超参数标注在它们各自起作用的位置

一轮迭代 = 采样 → 算优势 → 多轮更新 → 调LR;训练日志每一行就是一轮(见第7章)



被训练的「网络」(全程结构固定)

- Actor / Critic = MLP [256,128,64]
(多层感知机,属 DNN 一种)
- 激活函数 ELU · 噪声 std=0.28
- 左侧①~④是 PPO「训练法」,
改的是这些网络的权重
- max_grad_norm=0.5 · max_iter=12000

网络 = 被训练的「大脑」(学生)
PPO = 更新权重的「教学法」(强化学习)
clip 把更新限在 $\pm 20\%$ (小步走),
避免一步跳太远把抓取学崩。